

ANONIMIZZAZIONE DATI SANITARI

Progetto combinato di
FDSML & NLP



Consiglio Luigi
Ferrara Francesco
A.A. 2024/2025

INDICE

L'obiettivo principale di questo progetto è l'utilizzo di specifiche tecniche per l'addestramento di modelli di Machine Learning ed NLP per l'anonimizzazione di dati sensibili.



1

Introduzione

2

Dataset

3

Statistica

4

Machine Learning

5

Natural Language
Processing

6

Conclusioni


INTRODUZIONE

DESCRIZIONE DEL PROBLEMA



Il problema dell'anonimizzazione dei dati riguarda la trasformazione di dataset contenenti informazioni personali o sensibili in una forma che impedisca di risalire **all'identità** degli individui.

RESEARCH QUESTION




1. Quali fattori influenzano maggiormente l'esito dei **test clinici**?
2. Come si comportano i principali **modelli di ML** di fronte al dataset scelto?
3. Quanto è efficace la **RegEx nell'anonimizzare** automaticamente le note cliniche generate?
4. Quanto è efficace la **NER nell'anonimizzare** automaticamente le note cliniche generate?

HEALTHCARE DATASET

Il dataset è formato da **dati sintetici** ed è progettato per imitare i dati sanitari del mondo reale.

Ogni colonna fornisce **informazioni specifiche** sul paziente, sul suo ricovero e sui servizi sanitari ricevuti, rendendo questo dataset adatto a diversi compiti di analisi dei dati.

- Il dataset presenta:
- 50 mila righe;
 - 15 colonne (14 feature e 1 variabile target);
 - 534 duplicati;
 - nessun dato mancante.



△ Name	# Age	△ Gender	△ Blood Type	△ Medical Condition
Name	Age	Gender	Blood Type	Medical Condition
49992 unique values	 1389	Male50% Female50%	A-13% A+13% Other (41575)75%	Arthritis17% Diabetes17% Other (36888)66%
Bobby JacksOn	30	Male	B-	Cancer
LesLie TErRy	62	Male	A+	Obesity
DaNnY sMitH	76	Female	A-	Obesity
andrEw waTtS	28	Female	O+	Diabetes

HEALTHCARE DATASET

Data Cleaning



Name	Age	Gender	Blood Type	Medical Condition	Date of Admission	Doctor	Hospital
Jeffery Johnson	40	Male	B-	Asthma	2021-10-24	Laura Sherman	Davis-Arroyo
Jeffery Johnson	42	Female	O+	Obesity	2023-09-26	William Johnson	Lutz Jackson Coffey, and
Jeffery Johnson	39	Male	B-	Asthma	2021-10-24	Laura Sherman	Davis-Arroyo
Jeffrey Henry	35	Male	AB+	Diabetes	2023-04-21	George Griffin	Walker Ltd
Jeffrey Henry	31	Male	AB+	Diabetes	2023-04-21	George Griffin	Walker Ltd
John Pugh	29	Male	O+	Hypertension	2023-03-24	Brian Miller	Fisher Ltd



Molte righe si differenziano solo per la feature **Age**.

Questo è dato dal fatto che i dati sono sintetici, e quindi si ispirano a dati **reali** ma non sono tali.

HEALTHCARE DATASET

Data Cleaning





Name	Age	Gender	Blood Type	Medical Condition	Date of Admission	Doctor	Hospital	Insurance Provider
Aaron Archer	47	Female	B-	Cancer	2021-01-10	Cynthia Villanueva	Montes Case and Mendez,	Medicare
Aaron Archer	49	Female	B-	Cancer	2021-01-10	Cynthia Villanueva	Montes Case and Mendez,	Medicare
Aaron Carr	59	Female	O-	Asthma	2023-06-20	Diane Davis	Jones, Holmes Kelley and	Blue Cross
Aaron Carr	60	Female	O-	Asthma	2023-06-20	Diane Davis	Jones, Holmes Kelley and	Blue Cross
Aaron Dalton	25	Male	O+	Arthritis	2022-08-22	Sarah Adams	Schroeder PLC	Blue Cross
Aaron Dalton	26	Male	O+	Arthritis	2022-08-22	Sarah Adams	Schroeder PLC	Blue Cross
Aaron Davis	75	Male	O-	Asthma	2023-01-26	John Reyes	Lee-Brown	Blue Cross
Aaron Davis	77	Male	O-	Asthma	2023-01-26	John Reyes	Lee-Brown	Blue Cross

Confrontando le righe che hanno in comune le feature **Name, Gender e Blood Type** si scopre che ci sono **4753 record** che differiscono per una sola colonna. Per la maggioranza si tratta della colonna **Age**.

HEALTHCARE DATASET

Data Cleaning



Le 4753 righe vengono **rimosse**, ma prima si verifica che questo non vada ad impattare la **variabile target Test Results**.
Inoltre si procede con la rimozione della feature **Room Number**.

STATISTICA DESCRITTIVA UNIVARIATA


L'analisi statistica univariata rappresenta un passo fondamentale nella comprensione dei valori presenti nel dataset.

Per prima cosa abbiamo analizzato le distribuzioni delle feature


Partendo da quelle numeriche...



Distribuzione età






Distribuzione Billing Amount



STATISTICA DESCRITTIVA UNIVARIATA


Per analizzare le feature **categoriche** abbiamo prima provveduto a svolgere il **one hot encoding** su di esse, e **label encoding** sulla feature target, ottenendo questi risultati:




STATISTICA DESCRITTIVA MULTIVARIATA

HEATMAP

In questa sezione analizziamo la matrice di correlazione per valutare le relazioni tra le variabili in esame, verificando se esistono legami significativi che possano influenzare l'interpretazione dei dati.



LEGENDA



STATISTICA DESCRITTIVA MULTIVARIATA



RISPOSTA ALLA RQ1:

QUALI FATTORI INFLUENZANO MAGGIORMENTE L'ESITO DEI TEST CLINICI?

La **heatmap** mostra che la maggior parte delle variabili numeriche non presenta forti correlazioni tra loro: la matrice è quasi tutta grigia, cioè vicina a zero.

In sintesi: **non** ci sono relazioni forti o particolari pattern tra le variabili del dataset.

MACHINE LEARNING

01

MODELLI DI ML

In questa fase, usiamo algoritmi come la **Random Forest** che imparano dai dati esistenti a riconoscere i pattern e a fare una previsione su "Test Results". **L'obiettivo** è costruire un modello che, una volta addestrato, sia in grado di **indovinare** correttamente **i risultati** anche su dati che non ha mai visto.

02

GRID SEARCH

La Grid Search è una tecnica di ottimizzazione degli **iperparametri** usata nel machine learning.

Nel nostro caso verranno messi a **confronto i risultati** prodotti dai modelli di ML precedentemente utilizzati con quelli prodotti dalla Grid Search per vedere se questa tecnica produrrà dei miglioramenti.



MODELLI DI ML

CREIAMO TRAIN SET E TEST SET

Viene utilizzato il rapporto **80%** (grandezza del Train set) a **20%** (grandezza del Test Set) rispetto alla grandezza totale del dataset.

Il **Train** set è quello che il modello usa per **imparare** a fare previsioni, mentre il **Test** set è una parte di dati che il modello non ha mai visto e che usiamo per **capire** se le sue previsioni sono affidabili.



RANDOM FOREST

La Random Forest è un algoritmo di machine learning supervisionato che **combina molti alberi decisionali**, ciascuno addestrato su campioni diversi del dataset e su sottoinsiemi casuali delle feature.

Nel nostro caso, stiamo usando la Random Forest per **prevedere il risultato del test** ("Test Result enc") a partire da molteplici feature dei dati.


	precision	recall	f1-score	support
0	0.33	0.33	0.33	3314
1	0.33	0.32	0.33	3344
2	0.33	0.34	0.33	3366
accuracy			0.33	10024
macro avg	0.33	0.33	0.33	10024
weighted avg	0.33	0.33	0.33	10024

MODELLI DI ML

REGRESSIONE LOGISTICA

La regressione logistica è un modello di classificazione supervisionato utilizzato per prevedere **l'appartenenza di un'osservazione a una o più classi.**

Nel nostro caso, abbiamo utilizzato la regressione logistica per **predire la variabile Test Result enc**, che rappresenta tre possibili esiti: Inconclusive (0), Normal (1) e Abnormal (2), sulla base delle altre feature del dataset.




	precision	recall	f1-score	support
0	0.33	0.20	0.25	3314
1	0.33	0.36	0.34	3344
2	0.33	0.44	0.38	3366
accuracy			0.33	10024
macro avg	0.33	0.33	0.32	10024
weighted avg	0.33	0.33	0.32	10024

MODELLI DI ML

SUPPORT VECTOR MACHINE (SVM)

L’**algoritmo SVM** è un modello di classificazione supervisionato che cerca di trovare le “**frontiere**” (iperpiani) che separano al meglio le **diverse classi nei dati**. SVM è particolarmente efficace quando le classi sono separabili da confini netti, ma può diventare meno efficiente se i dati non presentano pattern chiari.




	precision	recall	f1-score	support
0	0.34	0.20	0.25	3314
1	0.33	0.36	0.34	3344
2	0.33	0.44	0.38	3366
accuracy			0.33	10024
macro avg	0.33	0.33	0.32	10024
weighted avg	0.33	0.33	0.32	10024

MODELLI DI ML

NAIVE BAYES

Il **Naive Bayes** è un classificatore **probabilistico** che si basa sul teorema di **Bayes**, assumendo che le **feature** siano **indipendenti** tra loro (ipotesi “naive”).

Viene stimata la probabilità che ciascun esempio appartenga a una delle tre classi della Y. È un modello semplice e veloce, particolarmente adatto quando le feature sono realmente indipendenti e il dataset è ampio.



	precision	recall	f1-score	support
0	0.33	0.30	0.32	3314
1	0.33	0.34	0.33	3344
2	0.33	0.35	0.34	3366
accuracy			0.33	10024
macro avg	0.33	0.33	0.33	10024
weighted avg	0.33	0.33	0.33	10024

GRID SEARCH E RISULTATI

Nel nostro caso verranno **messi a confronto** i risultati prodotti dai modelli di ML precedentemente utilizzati con quelli prodotti dalla Grid Search per vedere se questa tecnica produrrà dei miglioramenti.



4. CONFRONTO RISULTATI: BASELINE vs OTTIMIZZATI

	Baseline	Ottimizzato	Miglioramento	Miglioramento %
Random Forest	0.3305	0.3333	0.0028	0.8452
Logistic Regression	0.3313	0.3313	0.0000	0.0000
LinearSVC	0.3315	0.3315	0.0000	0.0000
Naive Bayes	0.3295	0.3295	0.0000	0.0000

RISPOSTA ALLA RQ2:

COME SI COMPORTANO I PRINCIPALI MODELLI DI ML DI FRONTE AL DATASET SCELTO?

L'applicazione dei principali modelli di Machine Learning ha mostrato risultati equivalenti a una classificazione casuale. Tutti i modelli hanno raggiunto **un'accuracy intorno al 33%**, con precision, recall e f1-score distribuiti uniformemente tra le tre classi, senza alcun segnale di apprendimento significativo.

In conclusione, questo scenario evidenzia come il successo di un progetto di ML dipenda più dalla **qualità** e significatività dei dati che dalla scelta del modello stesso.

NATURAL LANGUAGE PROCESSING

01

GENERAZIONE DI NOTE CLINICHE

02

ANONIMIZZAZIONE TRAMITE REGEX

03

ANONIMIZZAZIONE TRAMITE MODELLI NER



CREAZIONE DELLE NOTE CLINICHE



- Per arricchire il dataset **è stata generata** per ogni riga una nota clinica **riassuntiva** in linguaggio naturale.

Tipo 1: Bobby Jackson, (Male, 30 years old, blood type B-) was admitted in Urgent mode. The patient was hospitalized on 2024-01-31 to Sons and Miller for Cancer. Patient insurance is Blue Cross. The Dr. Matthew Smith prescribed the Paracetamol. Tests have shown Normal results. The patient was discharged on 2024-02-02 with a billing amount in this range: \$18856.28.

Tipo 2: Leslie Terry: 62 years old, Male, blood type A+, was admitted on 2019-08-20 at Kim Inc due to Obesity, under Emergency admission. Insurance provider: Medicare. The attending physician, Dr. Samantha Davies, prescribed Ibuprofen. Test results indicated Inconclusive. The patient was discharged on 2019-08-26 with a total bill of \$33643.33.

Tipo 3: On 2022-09-22, Danny Smith (Female, 76 years old, blood type A-) was admitted to Cook PLC for treatment of Obesity (Emergency admission). Covered by Aetna, the patient was treated by Dr. Tiffany Mitchell who prescribed Aspirin. Tests revealed Normal. Discharge occurred on 2022-10-07 with a billing charge of \$27955.10.

GENERALIZZAZIONE DI AGE E BILLING AMOUNT

Prima di procedere con l'anonimizzazione, **generealizziamo Age e Billing Amount** convertendoli secondo questo schema:




Age

[13 ; 24]: young
[25 ; 38]: adult
[39 ; 59]: middle age
[60 ; 86]: elderly

Billing Amount

$\leq 10k$
 $\leq 20k$
 $\leq 30k$
 $\leq 40k$
 $\leq 50k$
 $> 50k$



[0 ; 10k]
(10k ; 20k]
(20k ; 30k]
(30k ; 40k]
(40k ; 50k]
(50k ; ∞)

ANONIMIZZAZIONE DEI DATI SENSIBILI

Scelte effettuate

In base al Regolamento Generale sulla Protezione dei Dati (**GDPR**) sono considerati dati personali tutte le informazioni che **identificano** o rendono identificabile **una persona** fisica, direttamente o indirettamente.



Feature anonimizzate

- Name
- Doctor
- Hospital
- Insurance Provider
- Date of Admission
- Discharge Date

Feature generalizzate

- Age
- Billing Amount

Feature non modificate

- Gender
- Blood Type
- Medical Condition
- Admission Type
- Medication
- Test Results



Mantenuti poiché, una volta scollegati dagli identificatori, non consentono la re-identificazione nel contesto del dataset.

GOLD DATASET



- Rappresenta un **insieme** di dati **di riferimento**, in cui le entità sensibili sono state annotate manualmente. Questo dataset non viene utilizzato per l'addestramento dei modelli, ma funge da **benchmark** oggettivo **per valutarne le prestazioni**.
- Ogni testo è accompagnato da una **lista di etichette** che identificano con precisione i segmenti sensibili.
- Confrontando i risultati prodotti dalla RegEx e dai modelli NER con le annotazioni del gold dataset, **possiamo valutare quanto i modelli siano efficaci** nell'individuare e anonimizzare le entità rilevanti.

Esempio di record nel gold dataset:

```
{
  "text": "Bobby Jackson: 30 years old, Male, blood type B-, was admitted to the hospital on 2024-01-31 at the Sons and Miller Blue Cross hospital, treated by Dr. Matthew Smith, and discharged on 2024-02-02.",
  "entities": [
    {"text": "Bobby Jackson", "label": "PERSON"},
    {"text": "2024-01-31", "label": "DATE"},
    {"text": "Sons and Miller", "label": "ORG"},
    {"text": "Blue Cross", "label": "ORG"},
    {"text": "Dr. Matthew Smith", "label": "PERSON"},
    {"text": "2024-02-02", "label": "DATE"}
  ]
},
```

METRICHE UTILIZZATE



Per valutare le prestazioni dei modelli sul nostro gold dataset, utilizziamo quattro metriche fondamentali: **accuracy, precision, recall e F1-score**.

Accuracy: su tutte le predizioni fatte dal modello (giuste e sbagliate, positive e negative), indica la **percentuale** di quante sono **corrette**. Nel nostro contesto indica, in generale, quanto il modello “indovina” correttamente le entità PERSON, ORG e DATE.




Precision: rappresenta la **proporzione** di entità che il modello ha **riconosciuto e** che sono **effettivamente corrette**. In altre parole, ci dice quanto il modello è “selettivo”, evitando falsi positivi (es. etichettare un ospedale come nome di persona).

METRICHE UTILIZZATE



Recall: su tutte le entità corrette che esistono **nel gold dataset**, indica **quante** il modello è riuscito a **riconoscere**. In pratica, indica quanto il modello è “sensibile” nel riconoscere tutte le **entità rilevanti, evitando falsi negativi** (es. non riconoscere una data importante nel testo).



F1-score: è la **media** armonica tra **precision e recall**, e fornisce una misura bilanciata tra le due. Nel nostro caso, è particolarmente utile perché evita che un modello con alta precision ma bassa recall, o viceversa, venga considerato buono solo su una delle due dimensioni.

Nel nostro progetto, queste metriche vengono calcolate confrontando le entità annotate nel gold dataset con quelle riconosciute dai modelli.

ANONIMIZZAZIONE TRAMITE REGEX

Un'espressione regolare (**Regex**) è una **notazione algebrica** che permette di **caratterizzare** un insieme di **stringhe**.

In altre parole, **sono sequenze di caratteri** che definiscono un modello di ricerca all'interno di stringhe di testo.



Nel contesto del progetto, **sono state impiegate per riconoscere e anonimizzare** automaticamente le colonne identificate come contenenti dati sensibili (es. Name, Doctor, Insurance Provider, ecc.), sostituendo i valori originali con etichette anonime.



Non è stata applicata la regex alla colonna Hospital: trattandosi di un attributo con un elevato numero di valori univoci e una variabilità simile a quella dei nomi propri, l'utilizzo di regex avrebbe potuto generare ambiguità e **falsi positivi** (es. confondere un nome di ospedale con un nome di persona).

ANONIMIZZAZIONE TRAMITE REGEX



Risultati:

```
REPORT ANONIMIZZAZIONE TRAMITE REGEX
Accuracy: 0.8000
Precision: 1.0000
Recall: 0.8000
F1-score: 0.8889
```

I valori ottenuti mostrano **ottima precision** (1.0), cioè ogni volta che la regex interviene lo fa correttamente senza introdurre falsi positivi. La recall (0.8) e di conseguenza l’F1 (0.89) risultano invece più basse, perché una parte delle entità non viene anonimizzata.

L’accuracy riflette il fatto che **il 20% delle entità gold non è stato anonimizzato**.

Questo è dovuto alle organizzazioni ospedaliere, su cui la regex **non è stata applicata**: il dataset contiene infatti circa 39.000 valori univoci su 50.000, quindi sarebbe impraticabile gestirli con semplici pattern regolari.

ANONIMIZZAZIONE TRAMITE REGEX



Risposta alla RQ3: Quanto sono efficaci le regular expression nell'anonimizzare automaticamente le note cliniche generate?

L'approccio basato su regex è molto **affidabile** in termini di correttezza, ma mostra una **copertura limitata** (come già discusso per le organizzazioni ospedaliere).


Per ottenere **un'anonimizzazione completa** sarebbe necessario integrare metodi più flessibili, come modelli NER, in grado di gestire la varietà lessicale del dominio medico.



ANONIMIZZAZIONE TRAMITE NER



- **La Named Entity Recognition** è una tecnica di NLP che permette di **identificare e classificare automaticamente** in un testo determinate entità, come nomi di persone, luoghi, organizzazioni, date o valori numerici.
- A differenza della RegEx **sfrutta modelli di apprendimento automatico** in grado di riconoscere le entità anche in contesti diversi, con maggiore flessibilità e capacità di generalizzazione.
- Stavolta viene inclusa anche la **colonna Hospital** nell'anonimizzazione: la NER infatti dovrebbe essere in grado di distinguere correttamente i nomi delle strutture sanitarie da quelli delle persone, riducendo il rischio di confusione.



MODELLI NER UTILIZZATI



Spacy (Sm, Md, Lg)



Bert



Flair

MODELLI NER UTILIZZATI

Spacy



SpaCy è una libreria di python che ha al suo interno dei modelli pre-addestrati per riconoscere le entità.

- **en** sta per english.
- **core** indica che è un modello principale.
- **web** significa che è stato addestrato su dati presi dal web.

sm, md, lg indicano la dimensione del modello: "small", "medium", o "large".


Più è grande, più è preciso, ma richiede più risorse.



L'uso combinato di questi modelli ci consente di confrontare prestazioni e compromessi: da un lato la **rapidità di esecuzione** (sm), dall'altro la **maggiore accuratezza** nell'anonimizzazione dei dati sensibili (lg).

MODELLI NER UTILIZZATI

Spacy



Aumento della
precisione

```
=====
📊 STATISTICHE COMPLETE:
♦ Modello: en_core_web_sm
📄 Campioni processati: 50
📊 Accuracy standard: 44.0%

Precision: 0.3827
Recall:      0.4404
F1-score:    0.4064
```

Small

```
=====
📊 STATISTICHE COMPLETE:
♦ Modello: en_core_web_md
📄 Campioni processati: 50
📊 Accuracy standard: 39.2%

Precision: 0.4580
Recall:      0.3915
F1-score:    0.4107
```


Medium

```
=====
📊 STATISTICHE COMPLETE:
♦ Modello: en_core_web_lg
📄 Campioni processati: 50
📊 Accuracy standard: 51.9%

Precision: 0.4691
Recall:      0.5186
F1-score:    0.4903
```

Large


Aumento della
velocità



MODELLI NER UTILIZZATI

Bert

- **Impara il linguaggio in generale:** viene prima "addestrato" su enormi quantità di testo, imparando il significato delle parole.
- **Si specializza per la NER:** a questo punto, viene affinato con un dataset più piccolo, dove le entità (persone, luoghi, ecc.) sono già etichettate.
- **Classifica le parole:** per ogni parola, decide se fa parte o meno di un'entità e, in caso affermativo, la classifica. Ad esempio, la parola "Milano" viene etichettata come "Luogo" perché BERT ha capito che si tratta di una città.



Le categorie di **BERT** sono state mappate sulle stesse usate con **spaCy**, in modo da avere un confronto uniforme (**PER** → **PERSON**, **ORG/LOC** → **ORG**).

Ma il modello non prevede direttamente entità come DATE, quindi ci siamo concentrati su **PERSON** e **ORG**.



MODELLI NER UTILIZZATI

Bert



```
=====
📊 STATISTICHE COMPLETE:
🔹 Modello: bert-large-cased-finetuned-conll03-english
📄 Campioni processati: 50
📊 Accuracy standard: 24.5%

Precision: 0.1691
Recall:    0.2454
F1-score:  0.1956
```

- Il modello è stato addestrato su un dataset (CoNLL-2003), che contiene testi di tipo newswire (**notizie giornalistiche**).
- Questo dominio è molto distante dai testi clinici, che includono terminologia medica, riferimenti a date di ricovero/dimissione, nomi di farmaci, ospedali e assicurazioni.
- Di conseguenza, il modello tende a confondere entità non rilevanti (es. “**Obesity**”, “**Male**”) con organizzazioni o altre entità, e manca nel riconoscimento di entità chiave come **DATE** o **PHI** specifici.

MODELLI NER UTILIZZATI

Flair



Flair è un'altra libreria per il linguaggio naturale, che funziona in maniera simile a BERT.

Flair è noto per la sua alta precisione e la capacità di gestire anche le parole mai viste prima, perché si basa sui caratteri che le compongono.

Anche per Flair estraiamo **PERSON** e **ORG**.

```
=====
📊 STATISTICHE COMPLETE:
💎 Modello: Flair-NER-Fair
📄 Campioni processati: 50
📈 Accuracy: 34.0%

Precision: 0.3753
Recall:    0.3397
F1-score:  0.3551
```


I risultati ottenuti con Flair indicano una **capacità limitata** del modello nel contesto medico-sanitario.

Infatti Flair-NER-Fair **è un modello generale**, non specificamente addestrato su test clinici.

Nonostante la sua architettura avanzata, **la mancanza di adattamento al dominio sanitario** riduce le prestazioni quando il focus è sull'anonimizzazione di cartelle cliniche sintetiche.

MODELLI NER UTILIZZATI

Confronto



Tenendo conto che non consideriamo la regex perché non viene anonimizzata la feature Hospital, dal grafico emerge subito che **spaCy-large supera tutti gli altri modelli** su tutte le metriche, confermandone l'efficacia nel contesto clinico.

ANONIMIZZAZIONE TRAMITE NER

Risposta alla RQ4: Quanto è efficace la NER nell'anonimizzare automaticamente le note cliniche generate?



La NER può anonimizzare **alcune entità chiave** come date, nomi di pazienti e medici, e assicurazioni, ma le prestazioni **dipendono** molto dal **modello utilizzato**. I modelli generici **faticano** a riconoscere correttamente entità cliniche complesse e introducono errori o confondono categorie simili.

I modelli più grandi e sofisticati catturano meglio le informazioni rilevanti, ma **non sono perfetti** e continuano a mancare alcune entità.



In **conclusione**, la NER è più flessibile delle regex, ma per un'anonimizzazione completa e affidabile **servirebbero modelli addestrati specificamente su testi clinici**.

CONCLUSIONI E SVILUPPI FUTURI

Per migliorare ulteriormente il nostro workflow di anonimizzazione, alcuni possibili sviluppi includono:

- addestramento di **modelli NER specifici** per il dominio clinico;
- espansione delle regole regex e delle categorie di entità;
- integrazione di approcci di anonymization avanzati come **k-anonymity**;
- utilizzo di **combinazione di regex e NER** per migliorare le prestazioni;
- utilizzo di modelli di **IA generativi**;



GRAZIE PER L'ATTENZIONE



<https://github.com/luicons01/Progetto-FDSML-NLP>